

GEDS - Grupo de Estudos de Data Science

Semana 7

Introdução à Amostragem e Inferência Estatística

Links Fixos

Livro PDF Teórico:

https://edisciplinas.usp.br/pluginfile.php/4445638/mod_resource/content/1/Book_EstatBas% 20-%20Morettin%20%20Bussab.pdf

Site educativo:

https://seeing-theory.brown.edu/basic-probability

Capítulo 10

Livro Estatística Básica - Morettin e Bussab

Introdução a amostragem - explicação sobre o contexto da amostragem e os tipos de amostra

https://drive.google.com/a/pyfound.org/file/d/18ccmlA3v7C-Jh_TSEIWat7r3qPkaFEJa/view?usp=drivesdk

Artigo Sobre Viés na Seleção de Amostra

Health Indicators: Eliminating bias from convenience sampling estimators Bethany L. Hedt and Marcello Pagano https://www.ncbi.nlm.nih.gov/pmc/articles/PMC3951147/

Sobre viés em algoritmo e como ajustar isso

https://www.ere.net/dont-embed-your-bias-in-your-algorithm/

Exemplo dos casos de contratação com viés de Etnia e Idade

https://www.linkedin.com/pulse/fix-labor-market-discrimination-bas-van-de-haterd/

Sobre o algoritmo com viés de contratação sexista da Amazon

https://www.ere.net/what-we-should-take-away-from-amazons-embedding-bias-in-its-algorithm-and-stopping-the-project/

https://www.theverge.com/2018/10/10/17958784/ai-recruiting-tool-bias-amazon-report

GEDS - Grupo de Estudos de Data Science



Parte prática

Usando os dados do Prodam vamos estimar a média salarial com a abordagem de

- a. Amostra Aleatória Simples
- b. Amostra Aleatória Estratificada
- c. Amostra Aleatória por Conglomerado

Amostra Aleatória Simples

Para criar uma amostra aleatória estratificada, há quatro etapas:

1) definindo a população;

Em nosso exemplo, a população é dos funcionários do Prodam de 2018. A população é expressa em N. Como estamos interessados em todos esses funcionários, podemos dizer que nossa população é de X. Se estivéssemos interessados apenas em funcionárias do Prodam, por exemplo, excluiríamos todos os homens na criação de nosso quadro de amostragem.

2) listando a população;

Precisamos identificar todos os funcionários.

3) escolhendo o tamanho da amostra; Informações mais detalhadas sobre esse cálculo em https://drive.google.com/file/d/1prfw8WCNZcarUZF4fslb5zphaxpHZoIF/view?usp=sharing

A fórmula para cálculo do tamanho da amostra para uma estimativa confiável da MÉDIA POPULACIONAL (μ) é dada por:

$$n = \left(\frac{Z_{\alpha/2} \cdot \sigma}{E}\right)^2$$

Equação 1

Onde:

n = Número de indivíduos na amostra

 $Z_{\alpha/2}$ = Valor crítico que corresponde ao grau de confiança desejado.

σ = Desvio-padrão populacional da variável estudada (no exemplo, RENDA).

 $= \qquad \text{Margem de erro ou ERRO MÁXIMO DE ESTIMATIVA. Identifica a diferença} \\ \text{máxima entre a MÉDIA AMOSTRAL } (\overline{X}) \text{ e a verdadeira MÉDIA}$

Precisamos definir qual Grau de Confiança adotaremos para encontrar o tamanho da amostra.



GEDS - Grupo de Estudos de Data Science

Tabela 1 - Valores críticos associados ao grau de confiança na amostra

Grau de Confiança	α	Valor Crítico Z _{ω/2}
90%	0,10	1,645
95%	0,05	1,96
99%	0,01	2,575

⁴⁾ selecionando a amostra.

Amostra Aleatória Estratificada

Para criar uma amostra aleatória estratificada, há sete etapas:

- 1) definindo a população;
- 2) escolha da estratificação relevante;

Se quiséssemos analisar as diferenças entre funcionários do sexo masculino e feminino, isso significaria escolher o sexo como estratificação, mas poderia envolver da mesma forma a escolha de funcionários de diferentes departamentos ou outras variáveis.

Para os fins deste exemplo, qual variável usaremos como estratos?

3) listando a população;

Precisamos identificar todos os funcionários.

4) listar a população de acordo com a estratificação escolhida;

Assim como nas técnicas de amostragem aleatória simples e de amostragem aleatória sistemática, precisamos atribuir um número consecutivo de 1 a NK a cada um dos funcionários em cada estrato. Como resultado, terminaríamos com duas listas, uma detalhando todos os funcionários do sexo masculino e outra detalhando todas as funcionárias.

5) escolhendo o tamanho da amostra;

Vamos imaginar que escolhemos um tamanho de amostra de 100 funcionários. A amostra é expressa como n. Esse número foi escolhido porque reflete o limite de nosso orçamento e o tempo que temos para distribuir nosso questionário aos funcionários, por exemplo. No entanto, também poderíamos ter determinado o tamanho da amostra necessário usando um cálculo de tamanho da amostra, que é uma ferramenta estatística particularmente útil.

6) calcular uma estratificação proporcional;

Imagine que dos funcionários, 60% deles são do sexo feminino e 40% do sexo masculino. Precisamos garantir que o número de unidades selecionadas para a amostra de cada estrato seja proporcional ao número de homens e mulheres na população. Para conseguir isso, primeiro multiplicamos o tamanho da amostra desejado (n) pela proporção de

pyladies São Paulo

GEDS - Grupo de Estudos de Data Science

unidades em cada estrato. Portanto, para calcular o número de mulheres necessário em nossa amostra, multiplicamos 100 por 0,60 (ou seja, 0,60 = 60% da população de funcionárias), o que nos dá um total de 60 mulheres. Se fizermos o mesmo com funcionários do sexo masculino, obteremos 40 homens (ou seja, 40% são do sexo masculino, onde $100 \times 0,40 = 40$). Isso significa que precisamos selecionar 60 funcionários do sexo feminino e 40 do sexo masculino para a nossa amostra de $100 \times 0,40 = 40$ 0.

7) usando uma amostra aleatória simples para selecionar sua amostra. Agora que escolhemos para nossa amostra 40 funcionários do sexo masculino e 60 do sexo feminino, ainda precisamos selecionar esses funcionários da população listada. Fazemos isso usando amostragem aleatória simples.